Simulação de 50 requisições: resultados e comparação de modelos

Relatório da execução concluída em 33 sementes. Comparação com MuSFiCO adaptado e Greedy nas três sementes comuns, sem novas simulações.

92,18%
Aceitação: 1.521 / 1.650

+26
Aceitas extras frente ao peso 1

6 ms
SLA SFC respeitado

Resultado do experimento completo

Com peso zero para a penalidade explícita de concentração, o modelo aceitou 1.521 sessões, contra 1.495 no peso 1: ganho de 1,58 ponto percentual. Melhorou em 19 sementes e empatou em 14; nenhuma semente teve redução do total aceito. O IC95% do ganho médio pareado é de 0,99 a 2,16 pontos percentuais.

Resultado do recorte comparativo

Nas sementes 42, 43 e 44, todas com 50 requisições, MAPPO + Qwen com orientações reproduzidas aceitou 130/150 (86,67%); MuSFiCO adaptado aceitou 128/150 (85,33%); Greedy aceitou 125/150 (83,33%). As topologias e cargas desse recorte foram conferidas por fingerprint.

Nos registros disponíveis, MuSFiCO e Greedy apresentaram menor latência média aceita; Greedy teve decisão mais rápida. Nosso modelo aceitou mais nesse recorte, mas isso não demonstra superioridade universal, nem equivale a uma comparação de 33 sementes para todos os algoritmos.

O que o documento contém

Cenário e funcionamento do orquestrador; tabela completa dos pesos; tabela dos três modelos nas mesmas sementes; gráficos de CPU, banda, tempo médio de decisão e latência. A taxa de aceitação também foi incluída para dar contexto ao consumo de recursos.

1. Cenário e desenho da comparação

As 33 sementes não são misturadas com as três sementes dos baselines.

Item	Descrição
Infraestrutura	25 servidores, CPU/memória 100 por nó; Erdős-Rényi p = 0,20; enlaces de 1 Gbps e 1-2 ms
Carga	50 requisições por semente; chegadas a cada 10 s virtuais; duração uniforme em [0,120] s
Sessões	Até 4 jogadores; 18 SFs distintas por sessão completa; CPU 20 e memória 15 normalizadas; FI exclusivo e BE parcialmente compartilhado
SLA e admissão	6 ms para comunicação/processamento da SFC; admissão imediata sem espera em fila; até 16 tentativas no MAPPO
Experimento A	Sementes 42-74; 1.650 requisições por peso; pesos 1 e 0; mesmo checkpoint e orientações reproduzidas
Comparação B	Sementes 42, 43 e 44; 150 requisições por modelo; mesmas topologias/cargas, validadas por hash

Como o orquestrador foi aplicado

O DAG preserva ramificações e junções, reserva recursos em todos os ramos e calcula o caminho crítico. Quatro atores MAPPO treinados propõem hosts regionais; o ranking escolhe apenas entre as propostas viáveis. O crítico global é usado no treino. A execução dos atores permanece centralizada em Python.

Qwen pré-treinado pode orientar os pesos e preferências do ranking. Neste ensaio, orientações reais do experimento anterior foram reproduzidas nos mesmos índices de requisição. Não houve novas chamadas ao Ollama nem treino. O valor load_balance_scale = 0 remove só a parcela explícita de carga; máscaras e limites físicos continuam obrigatórios.

A implementação usa cópia sob escrita, cache de candidatos/distâncias e extração única das observações. Saídas usam pasta exclusiva com data/hora, arquivos por semente e criação sem sobrescrita.

2. Resultado completo das 33 sementes

50 requisições por semente, 3.300 sessões avaliadas entre os dois pesos.

Métrica	Peso 1,0	Peso 0,0
Aceitas / total	1.495 / 1.650	1.521 / 1.650
Aceitação	90,606%	92,182%
Rejeições	155	129
CPU global média nas chegadas (%)	4,522	4,460
Banda média no tempo (%)	0,982	1,241
p99 do nó mais ocupado por chegada (%)	61,01	80,00
CPU máxima por nó (%)	71,14	100,00
Latência média aceita (ms)	4,597	4,565
Latência máxima aceita (ms)	5,999013	5,999129
Decisão média (ms)	115,47	110,44
Decisão p95 (ms)	286,03	216,39
Decisão p99 (ms)	446,05	427,92
Decisão máxima (ms)	638,32	809,02

Interpretação do tradeoff

A CPU média global caiu, mas o p99 do nó mais ocupado subiu de 61,01% para 80% e o máximo por nó atingiu 100%. A banda média aumentou de 0,982% para 1,241%. O ganho de aceitação exige maior concentração e maior consumo de banda, sem aumentar a capacidade dos servidores.

Média, p95 e p99 de decisão melhoraram, porém o máximo piorou de 638,32 para 809,02 ms. A vantagem não aparece em toda decisão individual. Foram 27 novas aceitações e 1 nova rejeição, saldo de +26. As 6.084 latências de fluxos aceitos com peso zero ficaram dentro de 6 ms.

3. Comparação com MuSFiCO e Greedy

Recorte das mesmas três sementes 42-44; não usar os 92,18% das 33 sementes para ranquear estes baselines.

Modelo	Aceitação	CPU média	Banda média	Latência	Decisão
MAPPO + Qwen (replay, peso 0)	86,67%	4,25%	1,16%	4,616 ms	110,77 ms
MuSFiCO (DP adaptado)	85,33%	4,14%	0,76%	4,176 ms	859,97 ms
Greedy (DAG)	83,33%	4,02%	1,41%	4,245 ms	31,09 ms

MAPPO + Qwen, peso zero

Maior aceitação nesse recorte: 130/150. A orientação foi reproduzida dos registros; o tempo de 110,77 ms não inclui novas gerações de texto nem a disputa de CPU com Ollama. O checkpoint e os mapeamentos são os da nova execução de 33 sementes, restritos aqui às três sementes comuns.

MuSFiCO adaptado

Adaptador local com recorrência de programação dinâmica inspirada no MuSFiCO, estendida ao DAG completo e limitada a quatro estados por camada. Aceitou 128/150, usou menos banda e apresentou menor latência média aceita. O tempo registrado foi maior. Não é o código oficial nem uma reprodução certificada dos resultados do artigo.

Greedy em DAG

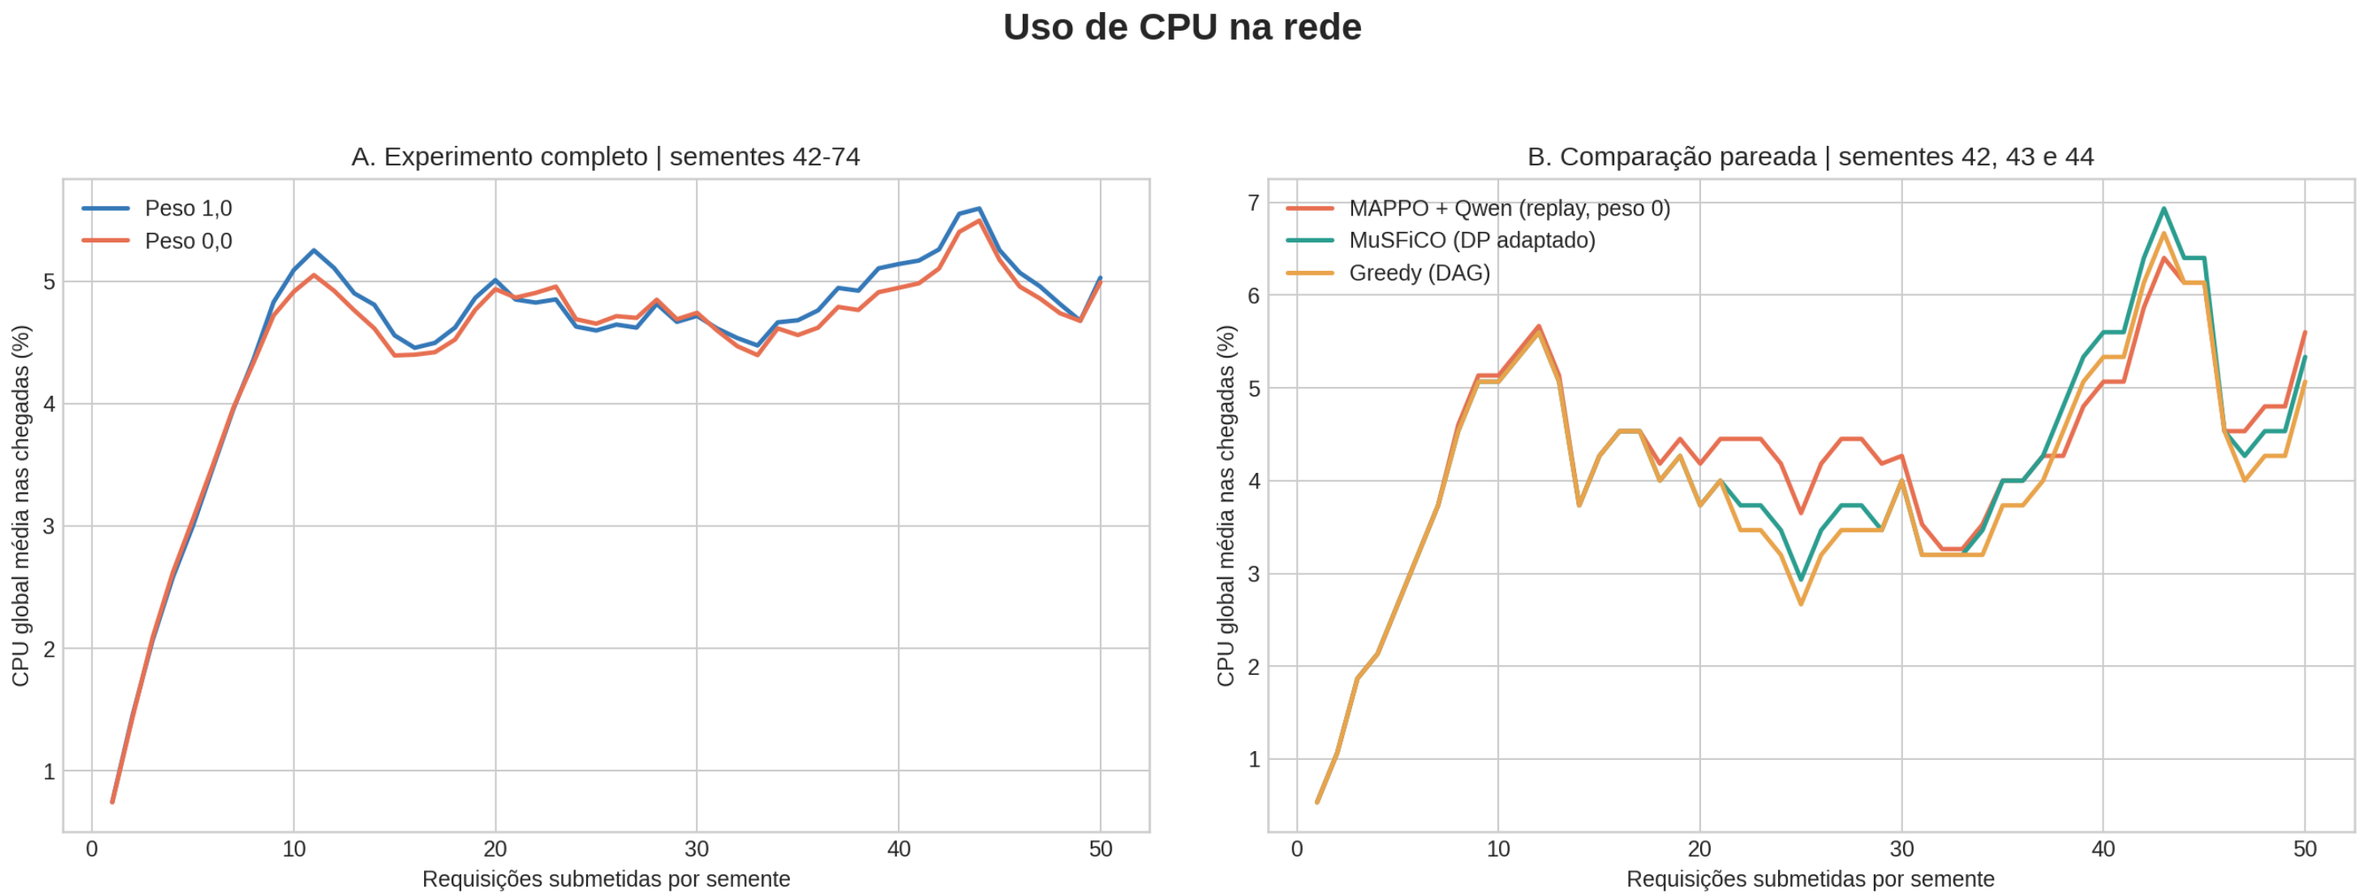
Heurística gulosa local com validação física: aceitou 125/150 e teve o menor tempo de decisão. Sua latência média aceita foi menor que a nossa, mas a utilização média de banda foi maior. A velocidade pode ser útil; o custo observado foi menor aceitação nesse recorte.

Limites da leitura

Os baselines foram medidos em execuções anteriores e não foram novamente executados após as otimizações. Os tempos descrevem versões e condições diferentes do controlador. As latências usam apenas o conjunto aceito por cada modelo. A diferença de 2 aceitações frente ao MuSFiCO, em três sementes, não sustenta uma conclusão estatística geral de superioridade.

4. Uso de CPU na rede

A: resultado completo de 33 sementes. B: comparação dos modelos nas mesmas três sementes.



50 requisições por semente nos dois painéis. A: 33 sementes; B: 3 sementes comuns. Baselines locais adaptados, medidos anteriormente.

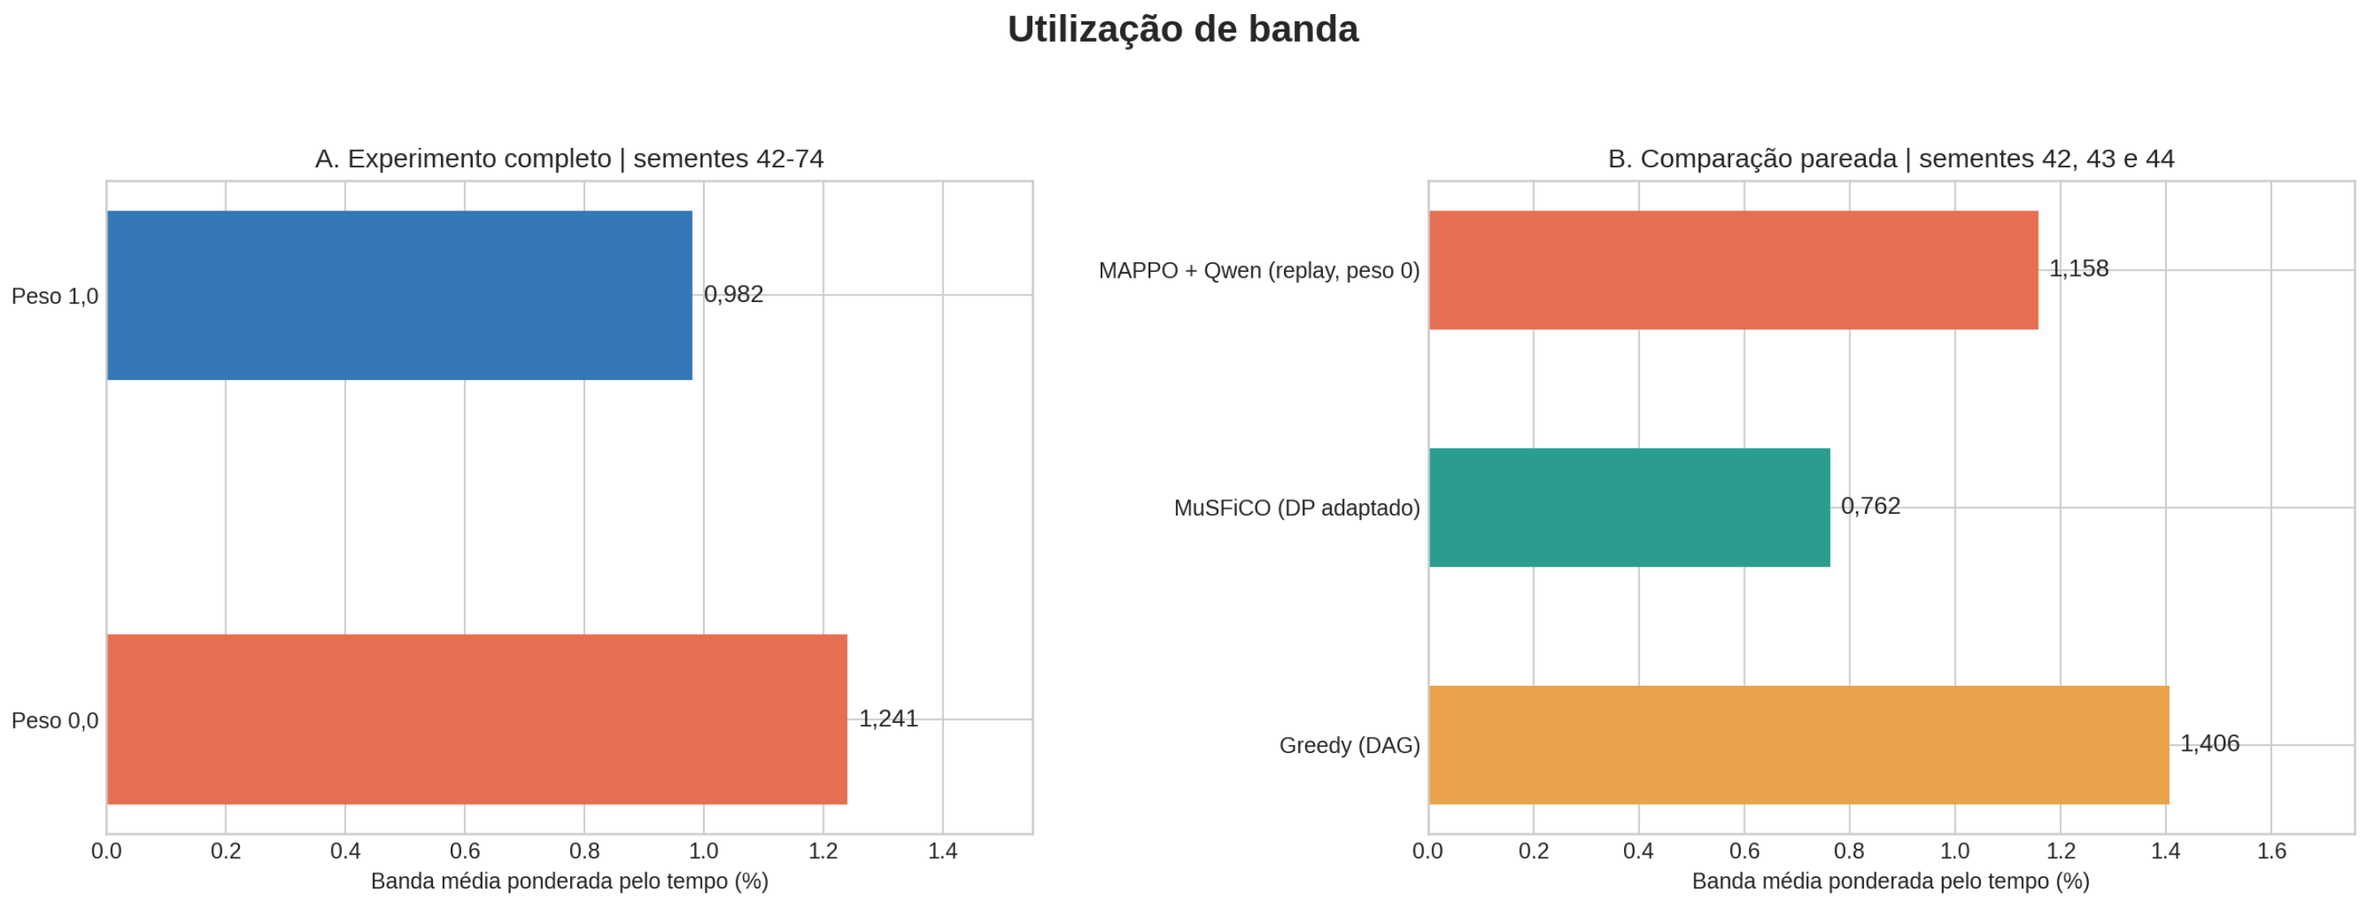
CPU simulada, não consumo do processador do PC

O painel A resume a utilização global ao longo das 50 chegadas em 33 sementes. O painel B usa apenas as três sementes comuns. Média global baixa pode coexistir com saturação local; o custo do peso zero aparece principalmente no pico por nó e no desequilíbrio.

MuSFiCO e Greedy são implementações locais. Cada semente submete 50 requisições. CPU é média nas chegadas; banda é ponderada pelo tempo; decisão é medida por sessão.

5. Utilização de banda

A: resultado completo de 33 sementes. B: comparação dos modelos nas mesmas três sementes.



50 requisições por semente nos dois painéis. A: 33 sementes; B: 3 sementes comuns. Baselines locais adaptados, medidos anteriormente.

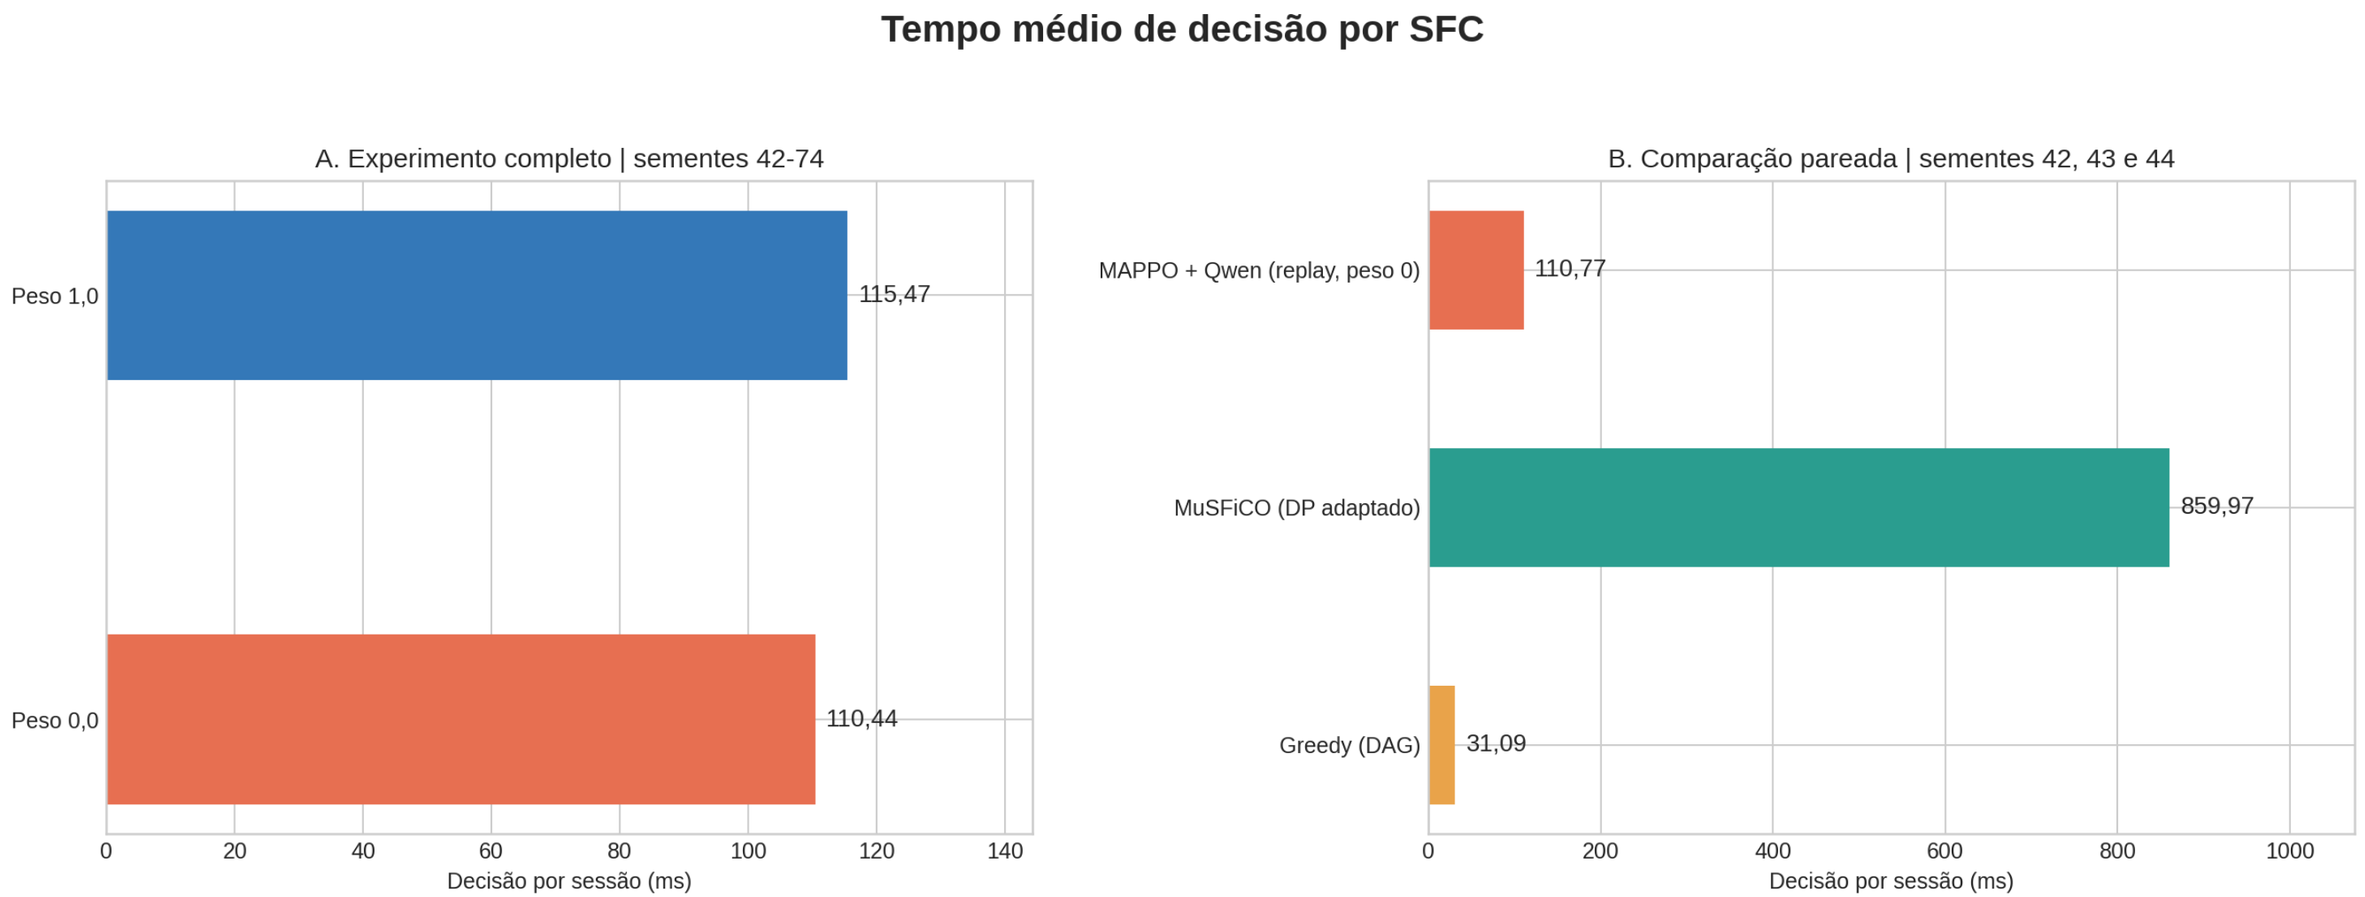
Banda média ponderada pelo tempo

O painel B compara 1,158% no nosso recorte, 0,762% no MuSFiCO adaptado e 1,406% no Greedy. Esses valores incluem o efeito das diferentes sessões aceitas. Menor consumo isolado não prova maior eficiência para atender a mesma carga.

MuSFiCO e Greedy são implementações locais. Cada semente submete 50 requisições. CPU é média nas chegadas; banda é ponderada pelo tempo; decisão é medida por sessão.

6. Tempo médio de decisão por SFC

A: resultado completo de 33 sementes. B: comparação dos modelos nas mesmas três sementes.



50 requisições por semente nos dois painéis. A: 33 sementes; B: 3 sementes comuns. Baselines locais adaptados, medidos anteriormente.

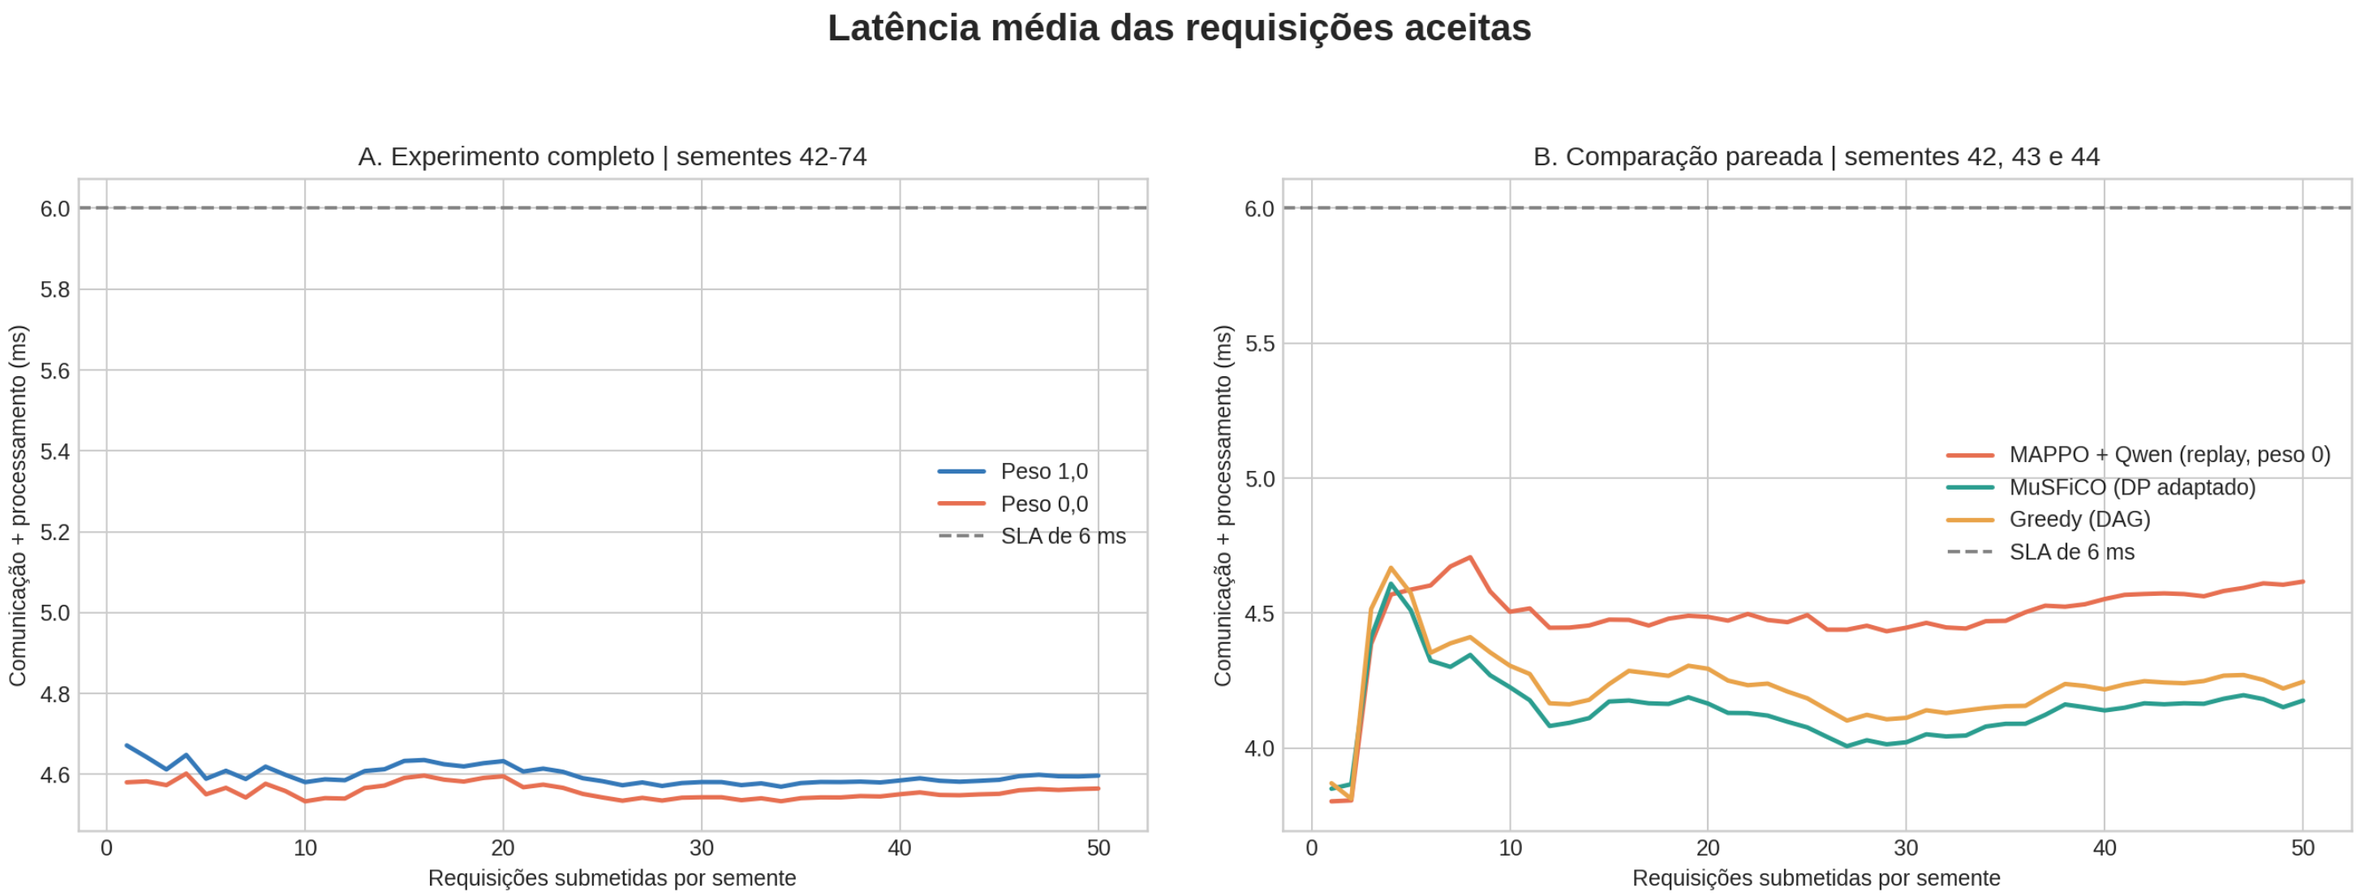
Tempo real da decisão, separado do SLA

O nosso replay não gera texto novo; MuSFiCO e Greedy não usam LLM. Os baselines históricos não receberam uma nova medição uniforme. As barras não comprovam o custo relativo dos algoritmos sob uma implementação e máquina controladas em uma mesma rodada.

MuSFiCO e Greedy são implementações locais. Cada semente submete 50 requisições. CPU é média nas chegadas; banda é ponderada pelo tempo; decisão é medida por sessão.

7. Latência média das requisições aceitas

A: resultado completo de 33 sementes. B: comparação dos modelos nas mesmas três sementes.



50 requisições por semente nos dois painéis. A: 33 sementes; B: 3 sementes comuns. Baselines locais adaptados, medidos anteriormente.

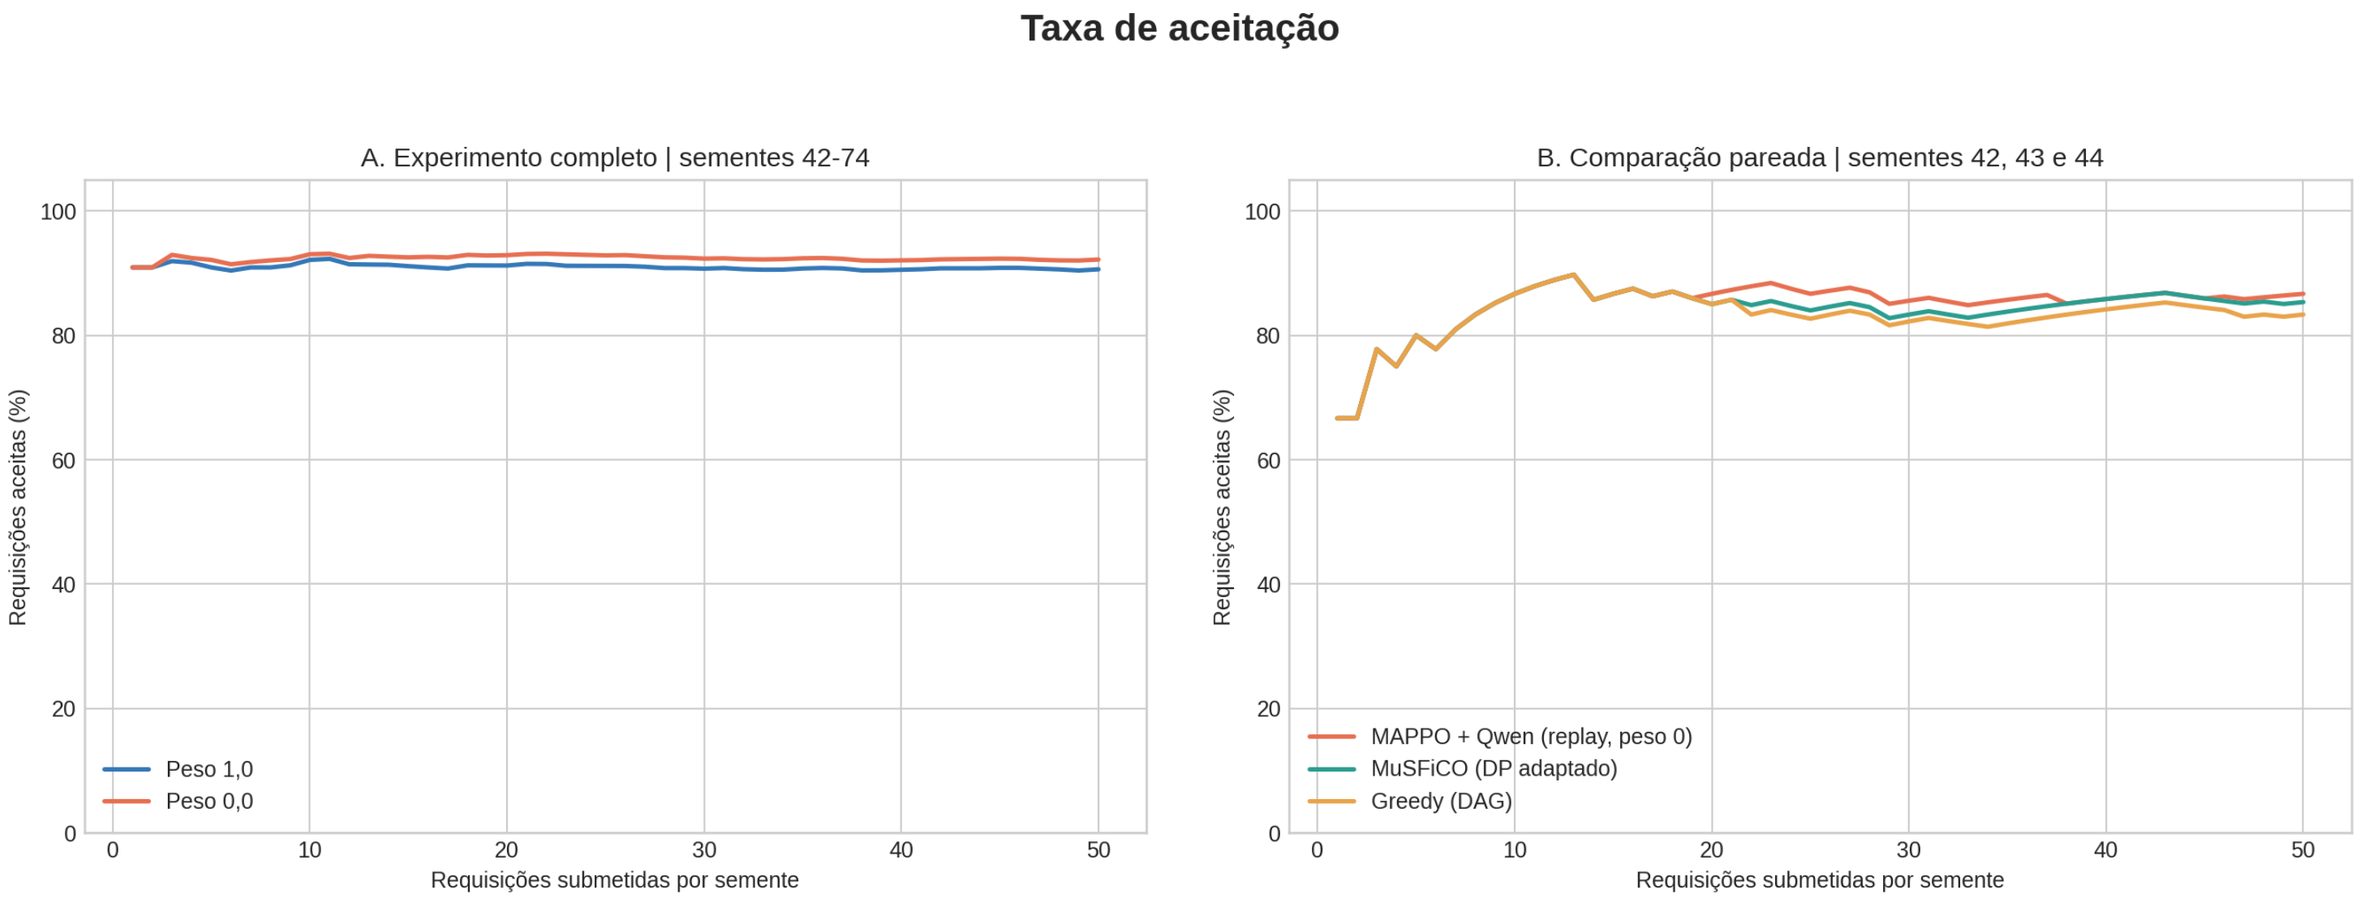
Latência média acumulada apenas das sessões aceitas

Todos os modelos têm os registros aceitos dentro de 6 ms. MuSFiCO e Greedy têm médias menores nesse recorte, enquanto nosso modelo aceita mais. Conjuntos aceitos diferentes e a ausência de renderização real limitam conclusões sobre a experiência visual em AR.

MuSFiCO e Greedy são implementações locais. Cada semente submete 50 requisições. CPU é média nas chegadas; banda é ponderada pelo tempo; decisão é medida por sessão.

8. Taxa de aceitação

A: resultado completo de 33 sementes. B: comparação dos modelos nas mesmas três sementes.



50 requisições por semente nos dois painéis. A: 33 sementes; B: 3 sementes comuns. Baselines locais adaptados, medidos anteriormente.

Mesma carga por semente; amostras distintas entre painéis

A aceitação das 33 sementes é 92,18% no peso zero. Para confrontar os baselines, utiliza-se somente o recorte de três sementes: 86,67% contra 85,33% e 83,33%. Os percentuais do painel A não devem substituir o recorte pareado do painel B.

MuSFiCO e Greedy são implementações locais. Cada semente submete 50 requisições. CPU é média nas chegadas; banda é ponderada pelo tempo; decisão é medida por sessão.

9. Avaliação, limites e fontes

Vantagem de aceitação no cenário avaliado, acompanhada de custos locais de concentração.

Consistência do resultado nas 33 sementes

O peso zero melhorou o total aceito em 19 sementes e empatou em 14, sem piora no agregado por semente. IC95% pareado do ganho: 0,994 a 2,157 pontos percentuais. Excluindo as três sementes do ajuste inicial, o ganho médio nas outras 30 foi de 1,533 ponto percentual, com IC95% de 0,923 a 2,144 pontos. Isso não é uma prova para toda rede ou carga.

Limite físico e relação com o ensaio de 300

Há 96 requisições excluídas pelo limite inferior físico de atraso ou por ausência de caminho; o teto otimista calculado é 94,182%, sem garantir a alocação de todas as demais. Restaram 129 rejeições no peso zero. Os resultados destas primeiras 50 requisições reproduzem os prefixos do experimento de 300: são dados relacionados, não uma validação estatística independente.

Qwen, tempo simulado e experiência visual

Orientação Qwen reproduzida em 996/1.650 requisições por peso. Chegadas e expirações são virtuais; tempos de decisão são reais. O replay padroniza quando a orientação é usada, mas não mede geração ao vivo ou interferência do Ollama. O SLA SFC não inclui a decisão e não comprova motion-to-photon, ausência de enjoo, filas reais ou capacidade de renderização.

Fontes e rastreabilidade

Execução: results/tradeoff_33_sementes_50_20261015_022202_401462. Auditoria: analysis_20261015_024037_529297/comparison.json. Baselines: results/muvr_comparison/{musfico,greedy}.json. Perfis, fingerprints e admissão imediata foram conferidos na comparação. Hashes SHA-256 e tabelas exportadas acompanham as figuras em dados_e_fontes.json.

MuSFiCO: Santos, Rosário, Cerqueira e Braun. Multi-criteria Service Function Chaining Orchestration for Multi-user Virtual Reality Services. GLOBECOM 2022, pp. 6360-6365. DOI 10.1109/GLOBECOM48099.2022.10000827. A publicação fundamenta a referência do método; os gráficos usam medições do adaptador local, não números oficiais do artigo.

Foram preservados os arquivos e relatórios anteriores. Este documento e suas figuras têm nomes exclusivos. Nenhum treino ou simulação foi iniciado para gerar este relatório.